

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO ĐỒ ÁN CUỐI KỲ

MÔN: HỌC THỐNG KÊ

ĐỀ TÀI: EMOTION CLASSIFICATION



Giảng viên hướng dẫn: ThS. Lê Long Quốc

Sinh viên thực hiện: Đỗ Quốc Thịnh — 23120089
Vũ Duy Thụ — 23120093
Cù Văn Nhựt — 23120153

Lớp: CQ2023/22

TP. Hồ Chí Minh, ngày 17 tháng 5 năm 2026

Mục lục

Danh mục hình ảnh	ii
Danh mục bảng biểu	iii
1 GIỚI THIỆU TỔNG QUAN	1
1.1 Lý do chọn đề tài	1
1.2 Mục tiêu của đề án	1
2 PHÂN TÍCH DỮ LIỆU VÀ MÔ HÌNH	1
2.1 Tập dữ liệu dair-ai/emotion	1
2.2 Khai triển kiến trúc mô hình BERT	2
2.2.1 Cấu trúc chi tiết mô hình BERT	2
2.2.2 Ưu điểm của mô hình	3
2.2.3 Nhược điểm của mô hình	3
3 QUÁ TRÌNH THỰC HIỆN VÀ KHÓ KHĂN	3
3.1 Khó khăn 1: Xử lý dữ liệu mất cân bằng	3
3.2 Khó khăn 2: Tối ưu hóa ngưỡng quyết định và chiến lược huấn luyện	4
3.3 Siêu tham số huấn luyện	4
4 KẾT QUẢ THỰC NGHIỆM	5
4.1 Theo dõi quá trình huấn luyện theo các Steps	5
4.2 Chỉ số đánh giá tổng quát trên Test Set	6
4.3 Đánh giá chuyên sâu qua Ma trận nhầm lẫn	7
5 XÂY DỰNG ỨNG DỤNG VÀ TRIỂN KHAI	9
5.1 Kiến trúc Server-Client với Docker	9
5.2 Triển khai với Docker Compose	9
5.3 Giao diện ứng dụng thực tế	9
5.4 Minh họa kết quả tương tác thực tế	9
5.5 Nhận xét về kết quả thử nghiệm thực tế	11
6 ĐÁNH GIÁ ĐỀ ÁN	11
6.1 Hạn chế của đề tài	11
6.2 Hướng phát triển tương lai	12
7 KẾT LUẬN	12

Danh sách hình vẽ

1	Phân phối nhãn cảm xúc trên các tập Train, Validation và Test	1
2	Kiến trúc chi tiết của một lớp Transformer Encoder trong BERT	2
3	Trọng số phạt (Class Weights) tính toán tự động theo nghịch đảo tần suất	4
4	Diễn biến hàm Loss trên tập Train và Validation theo từng Step huấn luyện	5
5	Biến thiên các chỉ số hiệu năng (Accuracy, F1-Macro và ROC-AUC) theo các Steps	6
6	Ma trận nhầm lẫn dạng số lượng đếm tuyệt đối và chuẩn hóa phần trăm tương quan	7
7	Giao diện khởi tạo hệ thống Chatbot Emotion Classification AI	9
8	Giao diện Chatbot hiển thị kết quả phân cài đặt light-dark mode	10
9	Giao diện Chatbot hiển thị kết quả phân tích cảm xúc của câu I miss my pen	10
10	Giao diện Chatbot hiển thị kết quả phân tích cảm xúc của câu I love you	10
11	Giao diện Chatbot hiển thị kết quả phân tích cảm xúc của câu the weather is sunny today	11

Danh sách bảng

1	Bố cục phân chia dữ liệu huấn luyện và kiểm thử	2
2	Siêu tham số huấn luyện mô hình	5
3	Bảng tổng hợp chi tiết các chỉ số hiệu năng thực nghiệm trên tập Test Set	7
4	Bảng thống kê kết quả thử nghiệm thực tế trên giao diện Chatbot	11

1 GIỚI THIỆU TỔNG QUAN

1.1 Lý do chọn đề tài

Trong thời đại bùng nổ dữ liệu số, việc hiểu được trạng thái cảm xúc ẩn sau văn bản không chỉ dừng lại ở mức độ tương tác cá nhân mà còn mang lại giá trị chiến lược trong kinh doanh, chăm sóc khỏe tinh thần và phân tích dư luận xã hội. Kiến trúc Transformer, với cơ chế *Self-Attention* vượt trội, đã mở ra kỷ nguyên mới cho NLP, thay thế các mô hình tuần tự truyền thống. Nhóm lựa chọn đề tài này để nắm vững quy trình từ huấn luyện mô hình học sâu đến triển khai sản phẩm thực tế.


1.2 Mục tiêu của đồ án

- Nghiên cứu sâu về cơ chế *Self-Attention* và cách Transformer trích xuất đặc trưng ngữ cảnh.
- Thực hiện Fine-tuning thành công mô hình học sâu phục vụ bài toán phân loại đa nhãn.
- Tối ưu hóa hiệu suất mô hình thông qua các kỹ thuật xử lý dữ liệu mất cân bằng.
- Triển khai hệ thống hoàn chỉnh dưới dạng Microservices sử dụng Docker.

2 PHÂN TÍCH DỮ LIỆU VÀ MÔ HÌNH

2.1 Tập dữ liệu dair-ai/emotion

Dữ liệu đầu vào đóng vai trò quyết định độ chính xác của mô hình. Nhóm sử dụng tập dữ liệu *emotion* từ Hugging Face với tổng cộng 20,000 mẫu văn bản được gắn nhãn thủ công thành 6 cấu trúc cảm xúc độc lập.



Hình 1: Phân phối nhãn cảm xúc trên các tập Train, Validation và Test

Dựa trên Hình 1, nhóm ghi nhận sự mất cân bằng dữ liệu đáng kể giữa các lớp:

- **Lớp đa số:** *Joy* (5,362 mẫu) và *Sadness* (4,666 mẫu) chiếm tỷ trọng áp đảo trong tập huấn luyện (Train Set), tương đương lần lượt là 33.5% và 29.2%.
- **Lớp thiểu số:** *Surprise* (572 mẫu) và *Love* (1,304 mẫu) chiếm tỷ trọng rất nhỏ (chỉ khoảng 3.6% và 8.2%), đặt ra thách thức lớn đối với việc cập nhật trọng số đồng đều.
- **Tính nhất quán:** Tỷ lệ phân phối phần trăm các lớp được duy trì cực kỳ đồng nhất qua cả 3 tập huấn luyện, phát triển và kiểm thử, bảo toàn tính khách quan thống kê.

Bảng 1: Bố cục phân chia dữ liệu huấn luyện và kiểm thử


Thành phần	Số mẫu	Tỷ lệ %	Vai trò thực tế
Train Set	16,000	80.0%	Cập nhật hệ thống trọng số mô hình qua lan truyền ngược.
Validation Set	2,000	10.0%	Giám sát Overfitting và hỗ trợ điều chỉnh siêu tham số.
Test Set	2,000	10.0%	Đánh giá năng lực thực tế trên tập kiểm định độc lập.

2.2 Khai triển kiến trúc mô hình BERT

Nhóm lựa chọn mô hình nền tảng **bhadresh-savani/bert-base-uncased-emotion**. Đây là biến thể kiến trúc BERT-base đã được cấu hình tối ưu sẵn cho các tác vụ phân tích sắc thái biểu cảm ngôn ngữ. Mô hình sở hữu tổng cộng **109,486,854** tham số, và trong phạm vi đề án này, nhóm tiến hành thực hiện toàn vẹn quá trình **Full Fine-tuning** (tất cả các tham số đều tham gia cập nhật gradient).

2.2.1 Cấu trúc chi tiết mô hình BERT

Mô hình được cấu tạo từ nhiều lớp Transformer Encoder xếp chồng lên nhau. Mỗi lớp bao gồm các thành phần cốt lõi như cơ chế Self-Attention giúp học mối quan hệ giữa các từ, và các lớp Feed-forward để xử lý đặc trưng phi tuyến tính.



Hình 2: Kiến trúc chi tiết của một lớp Transformer Encoder trong BERT

Quá trình xử lý của BERT đi từ các Input Embeddings, qua các lớp tính toán Self-Attention để tạo ra Output Embeddings mang đậm thông tin ngữ cảnh hai chiều. Đây chính là lý do mô hình đạt được hiệu suất cao trong bài toán phân loại cảm xúc văn bản.

2.2.2 Ưu điểm của mô hình

- **Cơ chế học hai chiều (Bidirectional):** Khác với các mô hình LSTM truyền thống chỉ đọc từ trái sang phải, BERT đọc toàn bộ chuỗi văn bản cùng lúc. Điều này giúp mô hình hiểu rõ mối quan hệ giữa một từ với tất cả các từ đứng trước và sau nó, cực kỳ quan trọng để nhận diện các sắc thái cảm xúc tinh tế.
- **Pre-trained mạnh mẽ:** Được huấn luyện trên kho dữ liệu khổng lồ (Wikipedia và BooksCorpus), BERT đã sở hữu hiểu biết sâu sắc về ngôn ngữ trước khi được nhóm đưa vào huấn luyện chuyên biệt.
- **Uncased version:** Nhóm sử dụng phiên bản *uncased* (không phân biệt hoa thường) để giảm thiểu độ phức tạp của từ điển, vì trong giao tiếp chatbot, người dùng thường không tuân thủ nghiêm ngặt quy tắc viết hoa.


2.2.3 Nhược điểm của mô hình

- **Chi phí tính toán cao:** BERT có hàng triệu tham số (cụ thể là hơn 109 triệu tham số), đòi hỏi tài nguyên GPU lớn để huấn luyện và tạo ra một độ trễ nhất định khi thực hiện dự đoán theo thời gian thực.
- **Giới hạn độ dài chuỗi:** Kiến trúc mặc định chỉ hỗ trợ xử lý tối đa 512 tokens. Tuy nhiên, đối với bài toán phân tích cảm xúc dựa trên các câu thoại ngắn của người dùng, giới hạn này không phải là một rào cản quá lớn.

3 QUÁ TRÌNH THỰC HIỆN VÀ KHÓ KHĂN

3.1 Khó khăn 1: Xử lý dữ liệu mất cân bằng

- **Vấn đề:** Như đã chứng minh ở mục 2.1, các nhãn hiếm như *Surprise* chỉ chiếm 3.6% tổng dữ liệu. Nếu sử dụng hàm mất mát chuẩn, mô hình sẽ tối ưu hóa thiên kiến cho lớp đa số nhằm đạt cực đại hóa chỉ số Accuracy tổng thể.
- **Giải pháp:** Nhóm triển khai lớp kế thừa chuyên biệt `WeightedTrainer` sửa đổi phương thức `compute_loss`. Kỹ thuật sử dụng hàm phạt **Weighted Cross Entropy Loss** kết hợp làm mịn nhãn (*Label Smoothing* = 0.05). Trọng số mỗi lớp được tính theo nghịch đảo tần suất xuất hiện thực tế (Inverse Frequency):



Hình 3: Trọng số phạt (Class Weights) tính toán tự động theo nghịch đảo tần suất

Hệ thống tính toán gán trọng số phạt nặng cho lớp thiểu số *surprise* (4.6620) và *love* (2.0450), trong khi các lớp đa số như *joy* chỉ chịu hệ số phạt nhỏ (0.4973), ép buộc mô hình phải học cân trọng các nhãn hiếm.

3.2 Khó khăn 2: Tối ưu hóa ngưỡng quyết định và chiến lược huấn luyện

Trong quá trình huấn luyện, việc chọn learning rate phù hợp và quyết định thời điểm dừng là rất quan trọng để tránh tình trạng underfitting hoặc overfitting.

Nhóm đã áp dụng tổ hợp các kỹ thuật sau:

- **Cosine Learning Rate Scheduler:** Giúp learning rate giảm dần theo hàm cosine sau giai đoạn warmup, mang lại quá trình hội tụ mượt mà và hiệu quả hơn so với scheduler tuyến tính.
- **Early Stopping:** Với patience = 10, dựa trên metric *eval_f1_macro*.
- **Metric đánh giá:** Sử dụng F1-macro thay vì Accuracy để đảm bảo mô hình không "thiên vị" về các lớp đa số.

Nhờ đó, mô hình đã dừng huấn luyện sớm ở khoảng epoch 1.7 (step 350), tránh lãng phí tài nguyên tính toán và giảm nguy cơ overfitting, đồng thời đạt được kết quả tối ưu trên tập validation.

3.3 Siêu tham số huấn luyện

Trong quá trình thực hiện **Full Fine-tuning** mô hình **bhadresh-savani/bert-base-uncased-emotion** trên tập dữ liệu *dair-ai/emotion*, nhóm đã lựa chọn cẩn thận các siêu tham số nhằm đảm bảo sự ổn định, hội tụ tốt và giảm thiểu hiện tượng overfitting.

Các kỹ thuật quan trọng được áp dụng bao gồm Weighted Cross Entropy Loss để xử lý dữ liệu mất cân bằng, Label Smoothing để tăng tính tổng quát hóa, cùng với Cosine Learning Rate Scheduler và Early Stopping. Các siêu tham số cụ thể được sử dụng như sau:


Bảng 2: Siêu tham số huấn luyện mô hình

Siêu tham số	Giá trị	Mô tả / Lý do
Max Sequence Length	128	Phù hợp với độ dài câu ngắn trong dataset
Train Batch Size	16	Cân bằng giữa tốc độ và bộ nhớ GPU
Eval Batch Size	32	Batch lớn hơn khi đánh giá để ổn định
Learning Rate	5×10^{-6}	Giá trị nhỏ phù hợp cho fine-tuning
Epochs	3	Ngăn ngừa overfitting
Weight Decay	0.01	Giảm overfitting
Scheduler	Cosine	Giảm learning rate mượt mà
Label Smoothing	0.05	Làm mịn nhãn, tăng tính tổng quát
Loss Function	Weighted Cross Entropy	Xử lý dữ liệu mất cân bằng
Early Stopping	Patience = 10	Dựa trên F1-macro
Metric chọn best model	F1-macro	Ưu tiên cân bằng giữa các lớp
Precision	FP16	Tiết kiệm bộ nhớ và tăng tốc
Random Seed	42	Đảm bảo kết quả tái lập được

4 KẾT QUẢ THỰC NGHIỆM


4.1 Theo dõi quá trình huấn luyện theo các Steps

Hiệu năng của mô hình được giám sát liên tục thông qua việc ghi nhận giá trị hàm Loss và các chỉ số Accuracy, F1-Macro, ROC-AUC sau mỗi chu kỳ 100 bước huấn luyện (steps).



Hình 4: Diễn biến hàm Loss trên tập Train và Validation theo từng Step huấn luyện

Dựa trên đồ thị Loss theo Step (Hình 4), nhóm nhận thấy giá trị *Train Loss* giảm đều đặn từ mốc 0.6647 và hội tụ sâu. Song song đó, đường *Val Loss* dốc mạnh từ mốc 0.7599 (step 50), đạt điểm tối ưu cục bộ tại **step 350** với giá trị thấp nhất là **0.5112**, trước khi có sự dao động nhẹ do tác động của kỹ thuật phạt trọng số lớp thiểu số.



Hình 5: Biến thiên các chỉ số hiệu năng (Accuracy, F1-Macro và ROC-AUC) theo các Steps

Quan sát đồ thị biến thiên hiệu năng (Hình 5), năng lực phân loại của hệ thống ghi nhận các cột mốc cải thiện rất rõ rệt:

- **Accuracy:** Chỉ số độ chính xác tổng thể trên tập kiểm định tăng trưởng ổn định, khởi đầu từ mức 0.9255 (step 100) và đạt ngưỡng đỉnh **0.9430** tại vị trí step 350.
- **F1-Macro:** Tăng trưởng đồng nhất với Accuracy, bứt phá mạnh mẽ từ mốc 0.8800 và đạt giá trị tối ưu **0.9223** tại step 350. Việc hai đường biểu diễn duy trì khoảng cách hẹp và cùng đạt đỉnh chứng minh kỹ thuật *Weighted Cross Entropy Loss* đã điều hướng mô hình học rất tốt các đặc trưng của nhóm nhân thiểu số.
- **Hội tụ và dừng sớm:** Dựa trên cơ chế *Early Stopping* lấy thước đo *eval_f1_macro* làm trọng tâm, checkpoint tại **step 350 (checkpoint-350)** đã được hệ thống tự động lựa chọn làm trạng thái tối ưu nhất để nạp lại cho quá trình đánh giá tổng quát, giúp ngăn chặn hiện tượng quá khớp (overfitting) ở các bước lặp sau.

4.2 Chỉ số đánh giá tổng quát trên Test Set


Sau khi nạp lại checkpoint tối ưu nhất (**checkpoint-350**), nhóm tiến hành đánh giá hiệu năng tổng quát một cách khách quan trên tập dữ liệu Test Set độc lập gồm 2,000 mẫu hoàn toàn mới.

Bảng 3: Bảng tổng hợp chi tiết các chỉ số hiệu năng thực nghiệm trên tập Test Set

Chỉ số (Metric)	Giá trị ghi nhận	Ý nghĩa thống kê
Accuracy	0.9280	Tỷ lệ phân loại chính xác toàn cục trên toàn bộ tập dữ liệu kiểm thử.
F1-Score Macro	0.8852	Chỉ số F1 trung bình không tính trọng số, đại diện độ cân bằng các lớp.
F1-Score Weighted	0.9286	Chỉ số F1 trung bình có tính trọng số dựa trên mật độ phân bố lớp.
Precision Macro	0.8775	Khả năng dự đoán chính xác trong số các mẫu được phân loại dương tính.
Recall Macro	0.8939	Năng lực bao phủ, hạn chế bỏ sót các mẫu dương tính thực tế.
ROC-AUC Macro	0.9955	Khả năng phân tách tổng quát giữa các phân vùng nhãn cảm xúc khác nhau.

4.3 Đánh giá chuyên sâu qua Ma trận nhầm lẫn

Nhằm phân tích chi tiết các sai số cục bộ và nhận diện xu hướng phân loại của mô hình, nhóm tiến hành bóc tách Ma trận nhầm lẫn (Confusion Matrix) hiển thị dưới cả hai dạng: tần suất đếm tuyệt đối và giá trị chuẩn hóa theo tỷ lệ phần trăm (Hình 6).



Hình 6: Ma trận nhầm lẫn dạng số lượng đếm tuyệt đối và chuẩn hóa phần trăm tương quan

Từ kết quả thực nghiệm thu được trên ma trận, đối chiếu sâu với báo cáo chi tiết của từng nhóm cảm xúc, nhóm nghiên cứu nhận thấy phần lớn sai số dự đoán của mô hình không xảy ra một cách ngẫu nhiên. Thay vào đó, các lỗi phân loại đều khu trú và tập trung chủ yếu giữa các lớp cảm xúc có mức độ tương đồng cao về mặt ngữ nghĩa cũng như sắc thái biểu cảm:

- **Năng lực nhận diện ổn định trên các lớp đa số (Sadness và Joy):** Hai lớp dữ liệu chiếm mật độ lớn nhất trong tập huấn luyện là *sadness* và *joy* đồng thời

cũng đạt hiệu năng vượt trội nhất trên tập kiểm thử độc lập. Cụ thể, nhãn *sadness* đạt tỷ lệ Recall cao nhất toàn hệ thống với **96.90%** (phân loại chính xác 563 trên tổng số 581 mẫu), theo sát là nhãn *joy* với mức Recall đạt **93.67%** (dự đoán đúng 651 trên 695 mẫu). Quan sát trên ma trận chuẩn hóa cho thấy tỷ lệ nhầm lẫn từ hai nhóm này sang các lớp còn lại là tương đối thấp, chứng minh mạng nơ-ron đã thiết lập được không gian vector mang tính phân biệt cao. Kết quả này đến từ quy mô dữ liệu huấn luyện lớn và sự xuất hiện ổn định của các từ khóa mang đặc trưng ngữ cảnh hiển ngôn (như: *sad*, *lonely*, *depressed* cho miền tiêu cực và *happy*, *excited*, *wonderful* cho miền tích cực).

- Sự giao thoa ngữ cảnh và hiện tượng lệch tâm giữa miền Love và Joy:** Một trong những xu hướng sai số đáng chú ý nhất là việc mô hình thường xuyên dự đoán sai nhãn *love* thành nhãn *joy*, khiến chỉ số Recall của *love* dừng lại ở mức **84.91%**. Hiện tượng này hoàn toàn tương thích với bản chất tâm lý học ngôn ngữ. Do cả hai trạng thái đều thuộc miền cảm xúc tích cực (*Positive Valence*) và chia sẻ chung nhiều biểu thức từ vựng biểu thị sự hạnh phúc, mô hình có xu hướng quy hòa đặc trưng ngữ cảnh của các câu biểu cảm tình cảm gần bó gián tiếp về phân vùng vui vẻ tổng quát (ví dụ điển hình như mẫu câu: "*I love spending time with my family*"). Thêm vào đó, sự chênh lệch lớn về mật độ mẫu train giữa *love* (1,304 mẫu) và *joy* (5,362 mẫu) đã tạo ra một thiên lệch nội bộ, khiến mô hình ưu tiên phân vùng đa số khi tín hiệu ngữ nghĩa "tình cảm lãng mạn" chưa đủ cô lập.
- Thách thức phân vùng tại ranh giới quyết định hẹp của lớp Surprise:** Nhãn *surprise* là vùng chịu sai số phân loại nặng nhất hệ thống với chỉ số Precision thấp nhất toàn cục (70.27%) và Recall chạm mốc thấp nhất trong nhóm nhãn thiếu số (78.79%). Khảo sát ma trận nhầm lẫn cho thấy *surprise* thường bị dự đoán nhầm sang hai trạng thái đối nghịch là *fear* và *joy*. Về mặt ngôn ngữ tự nhiên, trạng thái "bất ngờ" có ranh giới ngữ cảnh rất nhạy cảm và phụ thuộc hoàn toàn vào cụm vị ngữ phía sau để phân hóa thành bất ngờ tích cực (kinh ngạc vui sướng → *joy*) hoặc bất ngờ tiêu cực (hoảng hốt sợ hãi → *fear*). Do các chuỗi văn bản đầu vào trong tập dữ liệu đa phần đều khá ngắn, kết hợp với mật độ dữ liệu huấn luyện của *surprise* quá thưa thớt (chỉ 572 mẫu, chiếm vốn vẹn 3.6%), mạng nơ-ron gặp rất nhiều khó khăn để tự tối ưu hóa một siêu phẳng phân tách ổn định cho nhóm cảm xúc này.
- Ranh giới phân vùng giữa hai nhóm Fear và Anger:** Hai nhóm cảm xúc tiêu cực này ghi nhận mức độ giao thoa tương đối thấp và kiểm soát sai số ở ngưỡng vừa phải. Kiến trúc Transformer đã học được tương đối tốt sự khác biệt bản chất giữa *fear* (thiên về lo lắng, hoảng sợ, bất an thông qua các token *afraid*, *nervous*, *scared*) và *anger* (thiên về tức giận, công kích thông qua các token *furious*, *hate*, *annoyed*). Sự phân hóa từ vựng tường minh này giúp mô hình hình thành các cụm đặc trưng khá tách biệt trong không gian biểu diễn. Tuy nhiên, hệ thống vẫn xuất hiện một lượng nhỏ mẫu *anger* và *fear* bị phân vùng lệch sang *surprise* do các câu này chia sẻ chung sắc thái cảm xúc mạnh và mang tính đột ngột.

Nhìn một cách tổng thể, các sai số phân loại của hệ thống hầu hết đều khu trú cục bộ giữa các nhóm cảm xúc có cùng tính chất tích cực hoặc tiêu cực (*Valence similarity*). Kết quả thực nghiệm này khẳng định kỹ thuật *Weighted Cross Entropy Loss* kết hợp *Label Smoothing* đã hoàn thành tốt vai trò điều hướng hàm mất mát trên tập dữ liệu lệch phân phối nghiêm trọng. Mặc dù vậy, để tối ưu hiệu năng phân tách các trạng thái cảm xúc tinh tế tại các phân vị biên đan xen phức tạp, hệ thống trong tương lai cần được mở rộng tích hợp thêm các kho ngữ liệu mở hoặc ứng dụng các kỹ thuật diễn giải chuyên sâu như trực quan hóa trọng số Attention.

5 XÂY DỰNG ỨNG DỤNG VÀ TRIỂN KHAI

5.1 Kiến trúc Server-Client với Docker

Hệ thống ứng dụng được thiết kế linh hoạt nhằm tối ưu hóa hiệu năng vận hành thực tế, chia tách thành hai dịch vụ độc lập cấu hình qua kiến trúc Microservices:


- **Backend (FastAPI):** Chịu trách nhiệm nạp mô hình tối ưu vào bộ nhớ và cung cấp API dự đoán tốc độ cao. Việc ứng dụng FastAPI giúp xử lý bất đồng bộ, giảm thiểu hàng đợi khi hệ thống tiếp nhận nhiều yêu cầu cùng lúc.
- **Frontend (Streamlit):** Cung cấp giao diện Chatbot trực quan, hỗ trợ tương tác thời gian thực và hiển thị các chỉ số xác suất dự đoán trực tiếp cho người dùng.

5.2 Triển khai với Docker Compose

Nhóm thực hiện đóng gói toàn bộ dự án vào Docker Image độc lập để đảm bảo tính nhất quán môi trường. Chỉ với một câu lệnh duy nhất: `docker-compose up --build`, hệ thống sẽ tự động thiết lập môi trường cô lập, cài đặt các gói thư viện phụ thuộc và nạp mô hình mà không gây ra bất kỳ xung đột nào với hệ điều hành máy chủ.

5.3 Giao diện ứng dụng thực tế

Dựa trên nền tảng Streamlit, nhóm đã triển khai một giao diện ứng dụng hiện đại mang tiêu đề **Emotion Classification**, tích hợp trực tiếp mô hình nền tảng **bhadresh-savani/bert-base-uncased-emotion** đã được Fine-tuned phục vụ bài toán phân loại cảm xúc người dùng.




Hình 7: Giao diện khởi tạo hệ thống Chatbot Emotion Classification AI

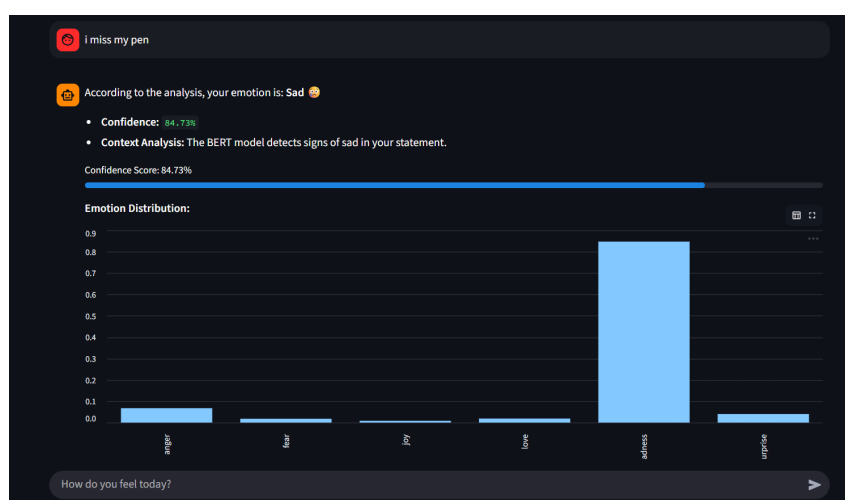
Như được thể hiện tại Hình 7, giao diện được cấu hình trực quan với khung nhập liệu dạng box chat, sẵn sàng tiếp nhận các chuỗi văn bản tự nhiên từ phía người dùng để đưa vào pipeline xử lý của mô hình.

5.4 Minh họa kết quả tương tác thực tế

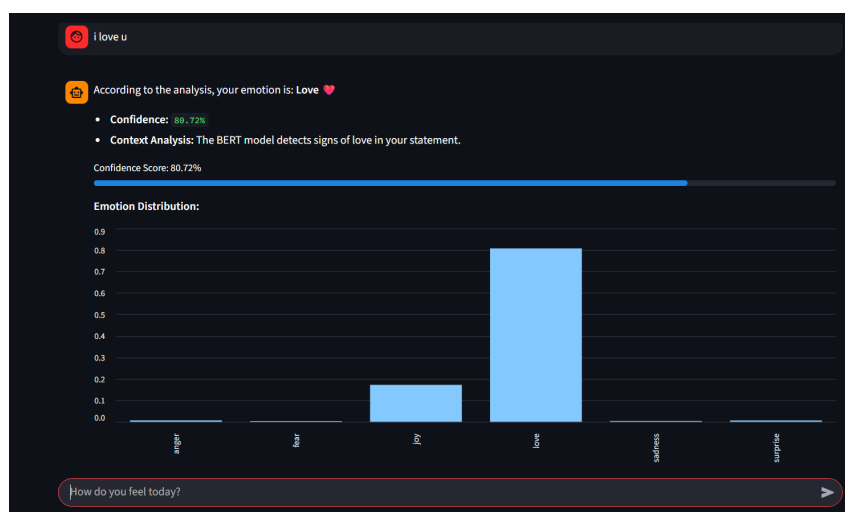
Nhằm đánh giá năng lực suy luận thực tế của mô hình sau khi đóng gói, nhóm tiến hành thực hiện chuỗi kịch bản kiểm thử tương tác trực tiếp trên giao diện box chat ở chế độ giao diện tối (Dark Mode).



Hình 8: Giao diện Chatbot hiển thị kết quả phần cài đặt light-dark mode



Hình 9: Giao diện Chatbot hiển thị kết quả phân tích cảm xúc của câu I miss my pen



Hình 10: Giao diện Chatbot hiển thị kết quả phân tích cảm xúc của câu I love you



Hình 11: Giao diện Chatbot hiển thị kết quả phân tích cảm xúc của câu the weather is sunny today

Dựa trên kết quả chạy thực nghiệm tương tác hiển thị trực tiếp trong khung chat của 3 câu trên, nội dung hội thoại và các nhãn cảm xúc tương ứng được tổng hợp lại trong bảng thống kê dưới đây:

Bảng 4: Bảng thống kê kết quả thử nghiệm thực tế trên giao diện Chatbot

STT	Văn bản nhập liệu (User)	Cảm xúc dự đoán (Bot)
1	i miss my pen	sadness
2	i love you	love
3	the weather is sunny today	joy

5.5 Nhận xét về kết quả thử nghiệm thực tế

Thông qua dữ liệu ghi nhận trực tiếp từ giao diện hội thoại (Bảng 4), nhóm đưa ra các nhận xét sau:

- **Khả năng nhận diện sắc thái chính xác:** Mô hình phân loại chuẩn xác câu mang tâm trạng mất mát, u buồn "i miss my pen" về đúng nhãn *sadness*. Đồng thời, câu biểu lộ tình cảm trực tiếp "i love you" và câu miêu tả trạng thái tích cực "the weather is sunny today" lần lượt được đưa về các nhãn *love* và *joy* một cách thuyết phục.
- **Tính thực tế của ứng dụng:** Giao diện chatbot Streamlit phản hồi kết quả trực quan ngay dưới dạng dòng hội thoại, chứng minh hệ thống hoạt động ổn định và có khả năng ứng dụng thực tế cao sau khi được đóng gói qua Docker.

6 ĐÁNH GIÁ ĐỒ ÁN

6.1 Hạn chế của đề tài

Mặc dù đạt được kết quả tốt, đồ án vẫn còn một số hạn chế sau:

- Mô hình còn nhầm lẫn giữa các nhãn có biểu hiện tương đồng (joy $\leftrightarrow$ surprise, fear $\leftrightarrow$ surprise).
- Chưa thử nghiệm các mô hình nhẹ hơn (DistilBERT, RoBERTa, DeBERTa) để so sánh.
- Dataset chỉ bằng tiếng Anh, chưa hỗ trợ tiếng Việt.
- Chưa thực hiện Ablation Study để đánh giá riêng tác động của từng kỹ thuật (class weight, label smoothing...).

6.2 Hướng phát triển tương lai

- Triển khai mô hình đa ngôn ngữ (Multilingual) hoặc chuyên biệt cho tiếng Việt.
- Phát triển mô hình multi-label emotion (một câu có thể có nhiều cảm xúc).
- Áp dụng quantization và pruning để tối ưu inference speed cho môi trường production.
- Xây dựng hệ thống Emotion Analysis cho mạng xã hội hoặc hỗ trợ tư vấn tâm lý.

7 KẾT LUẬN

Đồ án đã chứng minh được tính hiệu quả vượt trội của việc thực hiện Full Fine-tuning mô hình dựa trên nền tảng BERT trong bài toán phân loại cảm xúc văn bản đa nhãn. Thông qua việc kết hợp chặt chẽ giữa các kỹ thuật thống kê xử lý mất cân bằng dữ liệu đầu vào (Weighted Loss) và quy trình tối ưu siêu tham số nghiêm ngặt, nhóm đã kiểm định thành công hệ thống với chỉ số chính xác Accuracy đạt **92.80%** và không gian phân tách ROC-AUC đạt **0.9955**. Hệ thống ứng dụng hoàn chỉnh tích hợp Docker đảm bảo khả năng mở rộng dịch vụ và đáp ứng nhu cầu thực tế một cách ổn định.